


Practical part – Bar Rouso – I.D. 203765698

Question 1:


1. Binary Cross Entropy Loss with saturation:

Discriminator loss function: $E[\log(D(x))] + E[\log(1 - D(G(z)))]$

Generator loss function: $E[\log(1 - D(G(z)))]$




Final generated images from 64 fixed latent vectors:




2. Binary Cross Entropy Loss without saturation:

Discriminator loss function: $E[\log(D(x))] + E[\log(1 - D(G(z)))]$

Generator loss function: $E[-1 * \log(D(G(z)))]$




Final generated images from 64 fixed latent vectors:




3. Mean Squared Error Loss

Discriminator loss function: $E[\log(D(x))] + E[\log(1 - D(G(z)))]$

Generator loss function: $(1 - D(G(z)))^2$



Final generated images from 64 fixed latent vectors:



Analysis:

In both the first and the last cases, we can see that we run into a saturation:

The **Discriminator** loss **tends to ZERO** - Meaning it succeeded to returns 1 on real images (hence $E[\log(D(x))] = 0$) and returns 0 from generated images (hence $E[\log(1 - D(G(z)))] = 0$).

On the other hand, the **Generator** loss also **tends to ZERO** - Meaning it failed to convince the Discriminator that the images are generated is real.

Thus, it is almost impossible for the generator to learn something about the real distribution, as the Discriminator is too strong – hence we get garbage final images.

In the second case, we can see that we did **not** run into a saturation:


The **Discriminator** loss tends to 0.05-0.1 (It is difficult to see from the graph since the high jumps) – thus compare to the first case the loss tends to 10^{-8} , here the discriminator is not equally decidable about the generator images.

On the other hand, the **Generator** loss tends to 5-7 (again it is difficult to see from the graph due to the high jumps) – Meaning it succeeded in some cases to make the discriminator think it made a real image.

Thus, the generator succeeded to learn something about the real distribution, as the Discriminator is not too strong – hence we get final images that remind us of people.

Question 2:

Final inversion after 400000 iterations:



Final MSE Loss: 0.007872

Note: There is **no** degradation here, we just want to find the closest image that our generator can produce.

Explanation:

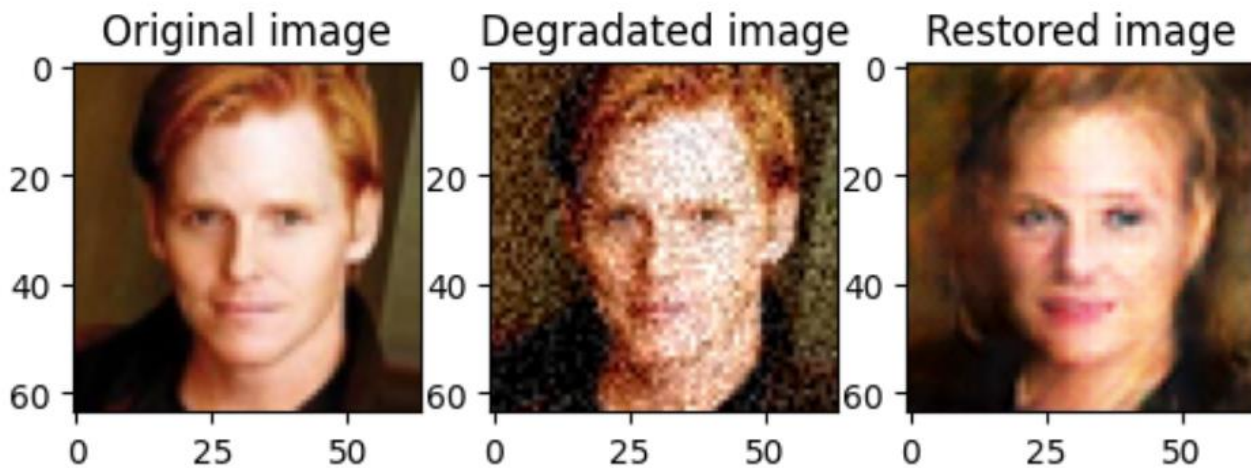
We can see that we got an inverted image that "reminds" of the original image in terms of the colors (face, hair, background, etc.).

On the other hand, there the inverted image seems much more blur and miss thin details (hair edges, earring, face outlines, etc.). This can be explained since in our optimization progress, we use MSE Loss which is known to yield blur images.

Using perceptual loss can fix this issue by comparing both images' "features", rather than checking how much the pixel values are close to each other.


Question 3:

Section 1 – Restoring image after adding a gaussian noise:



Final L1 Loss: 0.0626

Section 2 – erase 8x8 window:



Final L1 Loss: 0.0512

Explanation (for both sections):

We can see that in both sections:

- We got restored images that remind their original images (color and shape are similar).
- The restored images indeed succeeded to remove the Gaussian noise or fill the missing window in a way that make sense (here restored to noise part).
- Still, both images are far from being a 'good' reconstruction – this mainly can due to the fact that the Generator didn't succeed to generate authentic images from the real distribution, as it is not complex enough, or can be trained with better hyper-parameters.

I choose to use the **L1 norm loss** since it is more invariant to the above degradations (compare to L2 norm) in a sense that differences in pixels caused due to degradation will be less expressed by the final Loss, since we are not raising this impact by 2.

203465698

הערה חשובה - נא לכתוב את שם המורה

(1) הבה נגדיר את המרחב $GLOW$ כך N ו- 3 הם מספרים טבעיים: $W_{in} \times GLOW \rightarrow W_{out}$ ו- $h_{in} \times GLOW \rightarrow h_{out}$ כאשר $1 \leq j \leq W_{out}$, $1 \leq i \leq h_{out}$, $1 \leq k \leq C_{out}$ ו- C הוא מספר טבעי

$$(I) \gamma_{k,i,j} = [h_1(x)]_{k,i,j} = S \cdot X_{k,i,j} + b$$

כאשר S ו- b הם מטריצה וקטור בהתאמהכאשר $W_{in} = W_{out}$, $h_{in} = h_{out}$, $C_{in} = C_{out}$

$$(II) \gamma_{k,i,j} = [h_2(x)]_{k,i,j} = W \bar{X}_{ij}$$

כאשר \bar{X}_{ij} הוא המרחב $W \in \mathbb{R}^{C_{out} \times C_{in}}$ ו- $1 \leq j \leq W_{in}$, $1 \leq i \leq h_{in}$ כאשר $W \in \mathbb{R}^{C_{out} \times C_{in}}$ ו- $1 \leq j \leq W_{in}$, $1 \leq i \leq h_{in}$ כאשר $W_{in} = W_{out}$, $h_{in} = h_{out}$ ו- P הוא מטריצה

$$(III) \gamma = h_3(x) = [\gamma_a, \gamma_b]$$

כאשר γ_a ו- γ_b הם המרחב $1 \leq j \leq W_{in}$, $1 \leq i \leq h_{in}$, $1 \leq k \leq C_{in}$ כאשר $1 \leq j \leq W_{in}$, $1 \leq i \leq h_{in}$, $1 \leq k \leq C_{in}$

$$\gamma_b = X_b, \gamma_a = S \cdot X_a + \epsilon$$

כאשר $(\log S, \epsilon) = NN(X_1)$ כאשר N הוא המרחב $GLOW$ ו- N הוא המרחב

$$\underbrace{h_3 \circ h_2 \circ h_1}_{1} \underbrace{\circ h_3 \circ h_1}_{2} \dots \underbrace{h_3 \circ h_2 \circ h_1}_{n} = M^{-1}$$

כאשר $P(x)$ הוא המרחב $X \sim P(X)$, $Z \sim N(0, I)$ כאשר W ו- b הם מטריצה וקטור בהתאמה

⊂

$$p(x) = e^{\log p(x)}$$

$$: \frac{p'' \sim N}{\text{גורם}}$$

$$\log(p(x)) = \log(p_z(M^{-1}(x)) + \log\left(\left|\det\left(\frac{\partial}{\partial x} M^{-1}(x)\right)\right|\right) =$$

$$= \log\left(p_z\left(\prod_{t=1}^n [h_3 \circ h_2 \circ h_1](x)\right)\right) + \sum_{t=1}^n \sum_{q=1}^3 \log\left(\left|\det\left(\frac{\partial h_q}{\partial h_{q-1}}\right)\right|\right)$$

\uparrow $h_0 = h_3$
 \uparrow h_3
 \uparrow h_2
 \uparrow h_1
 \uparrow h_0

$$= \log\left(p_z\left(\prod_{t=1}^n [h_3 \circ h_2 \circ h_1](x)\right)\right) + \sum_{t=1}^n \left[h_{1,t,in} \cdot W_{1,t,in} \cdot C_{1,t,in} \cdot \log(u_{1,t}) \right] +$$

$$+ \left[h_{2,t,in} \cdot W_{2,t,in} \cdot \log(|\det(W_t)|) \right] +$$

$$+ \left[a_t \cdot \log\left(\left|\exp([NN(x_{b,t}))]\right|\right) \right]$$

: $1 \leq a \leq n$, $1 \leq t \leq n$ גורם פונקציה

$$h_{a,t} = \text{פונקציה } h_q \text{ בתור } t \quad (I)$$

$$h_{a,t} = C_{a,t,in} = \text{קבוע של פונקציה } h_q \quad (II)$$

$$h_{a,t} = W_{a,t,in} = \text{משקל של פונקציה } h_q \quad (III)$$

$$h_{a,t} = h_{a,t,in} = \text{קבוע של פונקציה } h_q \quad (IV)$$

$$a_t = \text{קבוע של פונקציה } h_q \quad (V)$$

$$x_{b,t} = \text{קבוע של פונקציה } h_q \quad (VI)$$

$$h_3 \text{ בתור } t$$

$$\text{GAN, GRO} \text{ מודלים שונים של } p(x)$$

$$\text{DATA} \text{ מודל של } p(x)$$

$$\text{GLOW} \text{ מודל של } p(x)$$

$$\text{GAN, GRO} \text{ מודלים שונים של } p(x)$$

$$\text{GAN, GRO} \text{ מודלים שונים של } p(x)$$

2) נגדן קטן \sim high/max

$$\min_G \max_D V(D, G) = \min_G \max_D \left[E_{p_{data}} [\log(D(x))] + E_{p_z} [\log(1 - D(G(z)))] \right]$$

sk זהו תהליך קטן, הטורצ'ר, כלומר D כדי להכנס δ classifier

$$D(x) \approx 1 \quad \text{עבור } x \text{ ממקור א} \\ D(G(z)) \approx 0 \quad \text{עבור } z \text{ ממקור ב}$$

הפונקציה $L(G)$ של G היא חצי סומה

$$L(G) = E_{p_{data}} [\log(D(x))] + E_{p_z} [\log(1 - D(G(z)))]$$

נניח $t_G \leftarrow G$ ונקרא t_G כפונקציה של G כך t_{G_0}

$$\frac{\partial L(G)}{\partial t_{G_0}} = \frac{\partial}{\partial t_{G_0}} \left(E_{p_{data}} [\log(D(x))] + E_{p_z} [\log(1 - D(t_G, z))] \right)$$

$$= \frac{\partial}{\partial t_{G_0}} \left(E_{p_z} [\log(1 - D(t_G, z))] \right) = \frac{\partial}{\partial t_{G_0}} \left(E_{p_z} [\varphi(t_G, z)] \right) = (*)$$

נניח $B(t_{G_0}, \delta)$ סביבה δ -סביבה סביב t_{G_0} , $t_G \in B(t_{G_0}, \delta)$ עבור $D(G(t_G, z))$ אזי $D(t_G, z) \geq \delta_{t_G}$

$$p_x [D(G(t_G, z)) \geq \delta_{t_G}] = 0 \quad \text{עבור } \delta_{t_G} < \alpha$$

כך $\varphi(t_G, z) := \log(1 - D(t_G, z))$ אזי $\varphi(t_G, z) \leq -\delta_{t_G}$

$$p_x [|\varphi(t_G, z)| \geq |\log(1 - \delta_{t_G})|] = 0$$

אם $E_{p_z} [\varphi(t_G, z)] < \infty$ אזי $\varphi(t_G, z)$ אינו מתפוצץ

$$\frac{\partial L(G)}{\partial t_{G_0}} = (*) = E_{p_z} \left[\frac{\partial}{\partial t_{G_0}} (\varphi(t_G, z)) \right]$$

היחס בין ϵ_0 ל- z

$$\frac{\partial}{\partial \epsilon_0} f(\epsilon_0, z) = \frac{\partial}{\partial \epsilon_0} (\log(1-x) \cdot D(\epsilon_0, G(\epsilon_0, z))) =$$

היחס בין ϵ_0 ל- z (היחס בין ϵ_0 ל- z)

$$\begin{aligned} & \frac{\partial}{\partial \epsilon_0} \underbrace{D(\epsilon_0, G(\epsilon_0, z)) - 1}_{\text{I}} \cdot \underbrace{\frac{\partial}{\partial G(\epsilon_0, z)} \cdot D(\epsilon_0, G(\epsilon_0, z))}_{\text{II}} \\ & \cdot \underbrace{\frac{\partial G}{\partial \epsilon_0} G(\epsilon_0, z)}_{\text{III}} \end{aligned}$$

כל המונחים הם חיוביים, לכן
I - חיובי, II - חיובי, III - חיובי

$$\frac{\partial L}{\partial \epsilon_0} = E_{P_z} \left[\frac{\partial}{\partial \epsilon_0} f(\epsilon_0, z) \right] \approx 0$$

כל המונחים הם חיוביים, לכן
היחס בין ϵ_0 ל- z חיובי
היחס בין ϵ_0 ל- z חיובי
היחס בין ϵ_0 ל- z חיובי

3 א) נסביר מדוע $\min_G(V(D, G))$ מנסה למצוא:

למקרה הזה דווקא.

בהינתן תמונה $I \in G$ מ"צ $V(D, G)$ של דיון
 עם D נותן δ -תמונה שאינה חלקה מול I עם I
 זו תמונה אחרת (אנחנו δ data) לא מציין
 (נוצר δ G).

עכשיו נבצע δ תמונה δ מנסה למצוא תמונה I
 סבב'ם (או z סבב'ם כך $G(z) = I$)
 כך $V(D, G)$ מניח δ מול D חלק
 מהא δ אחרת (צ"ן הכי קרוב δ)
 (נשים לב שיש דיוק ההערכה δ -collapsed)

ב) בהינתן סדרה $\min_G(V(D, G))$ הנכנסה -
 בלתי אלא G עם δ מנסה למצוא סבב'ם כך
 $G(z)$ חלקה מול D קרוב
 δ -1 מול תמונה אחרת (אנחנו δ data)
 הדעה $\max_D [\min_G (V(D, G))]$ מנסה למצוא

אם התחלנו עם D קיבלנו δ מול D בלתי
 נחלק δ מול G מ"צ, ולכן אינו קורה מול
 האחרת δ data

נשים לב שיש δ דעה δ מול G , בלתי מניח G
 כך מ"צ תמונה δ מול D דעה מרחוק בין δ מול
 האחרת δ data

התאריך - Data מהיום 13/8.